



Machine Learning

Preparação de dados: limpeza

Prof. Hugo de Paula

Preparação dos dados: limpeza e seleção de atributos

Campos podem ser irrelevantes, duplicados ou redundantes.

- podem produzir conhecimento falso.
- podem aumentar o tempo de execução dos algoritmos de data mining.

Preparação dos dados: engenharia de atributos

Exemplos:

- código postal é fundamental para construir relações geográficas.
- cpf não está relacionado com perfil (idade, sexo, cor, etc).
- data de nascimento e idade são informação duplicada.
- preço total = preço unitário * quantidade (dados redundantes)

Preparação dos dados: dados conflitantes

Exemplo: DB1 informa que João mora no Rio de Janeiro e DB2 informa que mora em São Paulo.

- Pode-se usar ambos (vive no Rio e em São Paulo).
- Pode-se usar o mais recentemente atualizado.
- Pode-se usar a fonte mais confiável.
- Pode-se sinalizar para ser investigado manualmente.
- Pode-se descartar registros conflitantes.

Aviso legal

O material presente nesta apresentação foi produzido a partir de informações próprias e coletadas de documentos obtidos publicamente a partir da Internet. Este material contém ilustrações adquiridas de bancos de imagens de origem privada ou pública, não possuindo a intenção de violar qualquer direito pertencente à terceiros e sendo voltado para fins acadêmicos ou meramente ilustrativos. Portanto, os textos, fotografias, imagens, logomarcas e sons presentes nesta apresentação se encontram protegidos por direitos autorais ou outros direitos de propriedade intelectual.

Ao usar este material, o usuário deverá respeitar todos os direitos de propriedade intelectual e industrial, os decorrentes da proteção de marcas registradas da mesma, bem como todos os direitos referentes a terceiros que por ventura estejam, ou estiveram, de alguma forma disponíveis nos slides. O simples acesso a este conteúdo não confere ao usuário qualquer direito de uso dos nomes, títulos, palavras, frases, marcas, dentre outras, que nele estejam, ou estiveram, disponíveis.

É vedada sua utilização para finalidades comerciais, publicitárias ou qualquer outra que contrarie a realidade para o qual foi concebido. Sendo que é proibida sua reprodução, distribuição, transmissão, exibição, publicação ou divulgação, total ou parcial, dos textos, figuras, gráficos e demais conteúdos descritos anteriormente, que compõem o presente material, sem prévia e expressa autorização de seu titular, sendo permitida somente a impressão de cópias para uso acadêmico e arquivo pessoal, sem que sejam separadas as partes, permitindo dar o fiel e real entendimento de seu conteúdo e objetivo. Em hipótese alguma o usuário adquirirá quaisquer direitos sobre os mesmos.

O usuário assume toda e qualquer responsabilidade, de caráter civil e/ou criminal, pela utilização indevida das informações, textos, gráficos, marcas, enfim, todo e qualquer direito de propriedade intelectual ou industrial deste material.



PUC Minas
Virtual

© PUC Minas • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.
Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.